

Projet DATAMINING M2 MIAGE — Analyse élections 2017 (1er tour)

Arezki BAZIZI & Riad KACEM

24/11/2025

1 Introduction

Ce rapport applique les méthodes d'**Analyse en Composantes Principales (ACP)** et de **classification non supervisée** (k-means et CAH) aux résultats du **1er tour 2017** de l'élection présidentielle, au **niveau départemental**.

Objectifs :

- Produire une synthèse descriptive des résultats au niveau départemental (agrégation pondérée par le nombre d'inscrits).
- Calculer une ACP normée sur les pourcentages départementaux pour extraire les axes structurants.
- Produire une classification non supervisée (K-means et CAH) pour faire émerger des profils départementaux.
- Cartographier les clusters sur une carte choroplèthe des départements.

2 Chargement et préparation des données

Cette première phase consiste à importer et à rendre exploitables les données brutes.

2.1 Nettoyage et conversion numérique

Les données brutes comportant des formatages textuels (virgules décimales, symboles %, espaces insécables), une fonction de nettoyage dédiée (`clean_num`) a été implémentée. Elle assure : • La conversion des virgules en points décimaux. • La suppression des symboles non numériques. • La transformation des chaînes de caractères en valeurs numériques (`numeric`).

Cette fonction est appliquée systématiquement aux colonnes de totaux (Inscrits, Votants, etc.) ainsi qu'aux colonnes de pourcentages des candidats.

3 Agrégation par département

L'agrégation est réalisée en calculant les pourcentages par département via une **moyenne pondérée par le nombre d'inscrits** de chaque commune.

Table 1: Synthèse des résultats : Abstention et principaux candidats (Top 10 départements)

Departement	Inscrits	Abstention (%)	Macron (%)	Le Pen (%)	Fillon (%)	Mélenchon (%)
Ain	415886	19.60	22.62	25.00	21.43	15.88
Aisne	375752	21.34	17.94	35.67	16.30	16.99
Allier	253508	21.41	23.72	22.34	18.94	19.91
Alpes-de-Haute-Provence	126578	19.22	20.02	24.53	18.49	22.51
Hautes-Alpes	109907	18.94	21.80	21.25	19.15	21.62
Alpes-Maritimes	761761	21.25	19.04	27.75	27.39	14.96
Ardèche	249258	18.70	21.64	23.17	17.30	21.80
Ardennes	194379	22.68	18.33	32.41	17.22	17.83
Ariège	117409	18.22	20.92	21.70	12.75	26.76
Aube	203847	19.11	18.98	30.33	23.05	13.97

4 Analyse descriptive

Cette étape permet d'étudier la **tendance centrale** (moyenne, médiane) et la **dispersion** (écart-type, étendue) de chaque candidat et des taux de participation à l'échelle départementale.

Table 2: Statistiques des scores des candidats par département (en % des exprimés)


Candidat	Moyenne	EcartType	Min	Mediane	Max
MACRON Emmanuel	23.01	4.13	12.75	22.33	40.40
LE PEN Marine	22.30	6.33	4.99	23.06	35.67
FILLON Francois	20.05	4.41	9.92	18.75	35.28
MELENCHON Jean-Luc	19.03	4.30	3.59	19.16	35.45
HAMON Benoit	6.31	2.40	2.91	5.85	25.22
DUPONT-AIGNAN Nicolas	4.71	1.23	1.48	4.89	7.18
LASSALLE Jean	1.49	1.22	0.46	1.06	7.55
POUTOU Philippe	1.24	0.51	0.62	1.17	5.24
ASSELINEAU Francois	0.93	0.28	0.58	0.86	2.41
ARTHAUD Nathalie	0.73	0.29	0.24	0.72	2.06
CHEMINADE Jacques	0.20	0.05	0.13	0.18	0.49

4.1 Histogramme de l'abstention

L'histogramme révèle généralement une distribution relativement symétrique. Cela indique que la majorité des départements se concentrent autour d'une moyenne nationale (le pic de la courbe), tandis que les départements à très forte ou très faible participation sont rares. C'est un indicateur de l'homogénéité relative du comportement électoral sur le territoire métropolitain.

Distribution du taux d'abstention par département

Présidentielle 2017 (1er tour)



5 Boxplot de l'abstention


Le boxplot permet de visualiser la médiane (trait central) et l'écart interquartile (la hauteur de la boîte, contenant 50% des départements).

Si la boîte est écrasée, les départements sont très homogènes.



Les points situés au-delà des "moustaches" (en haut ou en bas) signalent des départements atypiques (souvent les territoires d'Outre-mer ou la Corse qui ont des taux d'abstention structurellement différents de la métropole). Ces outliers sont importants à identifier avant une ACP car ils peuvent déformer les axes.


Dispersion de l'abstention (Boxplot)

Identification des valeurs médianes et atypiques



6 ACP





6.0.1 Interprétation (ACP)

L'ACP normée a été réalisée sur les pourcentages départementaux. Les deux premiers axes expliquent ensemble **57.7%** de l'inertie (PC1 = **42.1%**, PC2 = **15.7%**).

Axe 1 (PC1) : L'opposition Structurale

PC1 est l'axe majeur. Il oppose typiquement les départements où les variables **Taux Expression** et **Votes Nuls** sont fortes à ceux où **Abstention** et **Participation** dominent. L'interprétation classique est l'opposition Système vs. Anti-Système et/ou Vote de Mobilisation vs. Abstention/Vote Protestataire.

Conclusion : Cet axe résume la **fracture électorale historique**, polarisant le territoire entre les régions participant à la dynamique du scrutin et celles exprimant un rejet ou une distance.

Axe 2 (PC2) : La Clivage Résiduel

PC2 est indépendant du premier et met en évidence la distinction restante.

Il est principalement porté par les variables **Votes Blancs (Ins)** et **FILLON_Francois**. L'interprétation classique est le clivage Gauche Radicale/Protestataire (si Mélenchon/Hamon dominant un côté) vs. Droite Modérée/Conservatrice (si Fillon/Dupont-Aignan dominant l'autre côté).

7 Classification non supervisée

La classification est basée sur les **4 premières composantes principales**.

Le nombre optimal de clusters (Silhouette) est : 2

Table 3: Profils moyens des 2 clusters (K-means)

cluster	Pct_DUPONT- Aignan										Pct_MELENCHON_Jean- Luc										Votants
	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	Clus.1	Clus.2	
1	2.52	22.50	19.78	6.78	1.27	2.16	0.32	0.87	19.56	1.55	22.7	56.58	13.42	10.13	2.1	1.80	4.38	1.49	3.51	9	
2	4.92	22.28	23.31	6.26	0.68	1.15	0.19	1.55	18.99	0.88	19.8	20.46	79.54	77.47	7.4	1.45	1.81	0.63	0.79	98	




Table 4: Comparaison K-means vs. CAH (k= 2)

1	2
0	9
98	0


8 Carte choroplèthe

Question de recherche : Quel est le taux d'abstention par département au premier tour de l'élection présidentielle 2017 ?

Cette carte permet d'identifier la **géographie de la participation électorale** et de visualiser les départements où l'abstention est la plus forte ou la plus faible.

Taux d'abstention par département – 1er tour 2017

Pourcentage d'abstention parmi les inscrits



Source : Données électorales 2017

Table 5: Statistiques sur l'abstention par département

Moyenne	Mediane	Min	Max
19.9	19.81	15.71	32.76

9 Conclusion

Synthèse des Principaux Résultats Ce projet d'exploration des données électorales du premier tour de l'élection présidentielle de 2017, agrégées au niveau départemental, a permis d'atteindre les objectifs fixés :

Synthèse ACP : L'Analyse en Composantes Principales (ACP) a réussi à réduire la complexité des données. Les deux premiers axes principaux (PC1 et PC2) expliquent conjointement **57.7%** de la variance totale des pourcentages de vote départementaux. Ces axes capturent les grandes lignes de l'opposition électorale française : l'opposition structurante Système/Anti-Système (PC1) et le clivage Résiduel Gauche/Droite (PC2).

Synthèse Classification : La classification non supervisée par K-means a identifié r_best_k profils départementaux distincts (Tableau 1). Cette typologie fournit une cartographie des comportements électoraux français, révélant des groupes homogènes (par exemple, des départements à forte abstention, à forte concentration centriste, ou fortement orientés vers les extrêmes).

Synthèse Géographique : La carte choroplèthe des clusters confirme que les profils électoraux s'organisent selon des logiques spatiales claires, indiquant l'influence du contexte local (socio-démographie, économie régionale) sur le vote.

Limites du Projet et Perspectives Limites L'analyse présentée est sujette à plusieurs limites inhérentes au jeu de données et à la méthodologie :

Agrégation Départementale : L'utilisation de données agrégées au niveau départemental entraîne une perte de détail sur le plan communal et masque l'hétérogénéité interne des grands départements (l'effet de moyenne).

Variables Explicatives Manquantes : L'interprétation est purement électorale. L'absence d'intégration de variables socio-économiques externes (âge, diplôme, revenu, taux de chômage, etc.) limite la capacité à expliquer les causes profondes de la formation des clusters.

Traitement des NA : Le choix de l'imputation par la moyenne simple pour les valeurs manquantes introduit une simplicité qui peut légèrement biaiser la variance des variables.

Perspectives Pour enrichir et valider les résultats, les pistes suivantes sont recommandées :

Enrichissement des Données : Intégrer des indicateurs socio-économiques de l'INSEE par département. Cela permettrait d'effectuer une analyse de corrélation (ACP) enrichie et de nommer les clusters de manière plus pertinente (par exemple, "Cluster à forte abstention, faible revenu moyen").

Méthodes Alternatives : Si des variables catégorielles (ex. statut urbain/rural) devaient être ajoutées, l'utilisation d'une Analyse Factorielle des Correspondances Multiples (AFCM) serait plus appropriée que l'ACP classique pour étudier les relations entre les catégories.

10 Annexes

- Fichier `.Rmd` : code source utilisé.
- Fichiers produits : Figures PNG sauvegardées dans le répertoire de travail.
- Données : Les fichiers `Election2017_Tour1.csv`, `departements.geojson` et `elections_dept_agg_dept.csv` sont joints.